Sprawozdanie statystyka stosowana

Ignacy Boczula, Mateusz Dudek

10 października 2026

Wstęp

Celem projektu jest przeprowadzenie szczegółowej **analizy porównawczej** na wybranym zbiorze danych rzeczywistych w wykorzystaniem poznanych metod statystyki opisowej.

Interpretacji zostanie poddana wybrana zmienna, która zostanie pogrupowana ze względu na inną cechę kategoryzującą. Pozwoli to porównać, w jaki sposób ten podział **wpływa na rozkład badanych wartości**.

Aby zapewnić rzetelność wniosków, **weryfikacja postawionej hipotezy badawczej** zostanie przeprowadzona z wykorzystaniem odpowiednich testów statystycznych. Wyniki zostaną opracowane i zilustrowane w sposób pozwalający na interpretację wpływu badanego czynnika.

Opis zbioru danych

Podstawę badania stanowi popularny zbiór danych *Student Performance Data Set*, zaczerpnięty z bazy *UCI Machine Learning Repository*. Analizowany zbiór danych składa się z **397 obserwacji**, z których każda odpowiada pojedynczemu uczniowi oraz aż z **33 zmiennych**. Został on oryginalnie zebrany i opracowany w celu analizy i predykcji osiągnięć uczniów szkół średnich w Portugalii w zakresie matematyki.

Głównym celem tej analizy jest zbadanie, czy i w jakim stopniu **pochodzenie z obszarów wiejskich lub miejskich determinuje końcowe wyniki** egzaminować z matematyki. Posłużą do tego zmienne:

- **G1, G2, G3** - wyniki ucznia z egzaminów (dla kazdego przedział punktowy wynosi **od 0 do 20**), brak brakujących wartości
- **address** - zmienna kategoryzująca, **'U' - Urban (308 uczniów)** albo **'R' - rural (89 uczniów)**, brak brakujących wartości

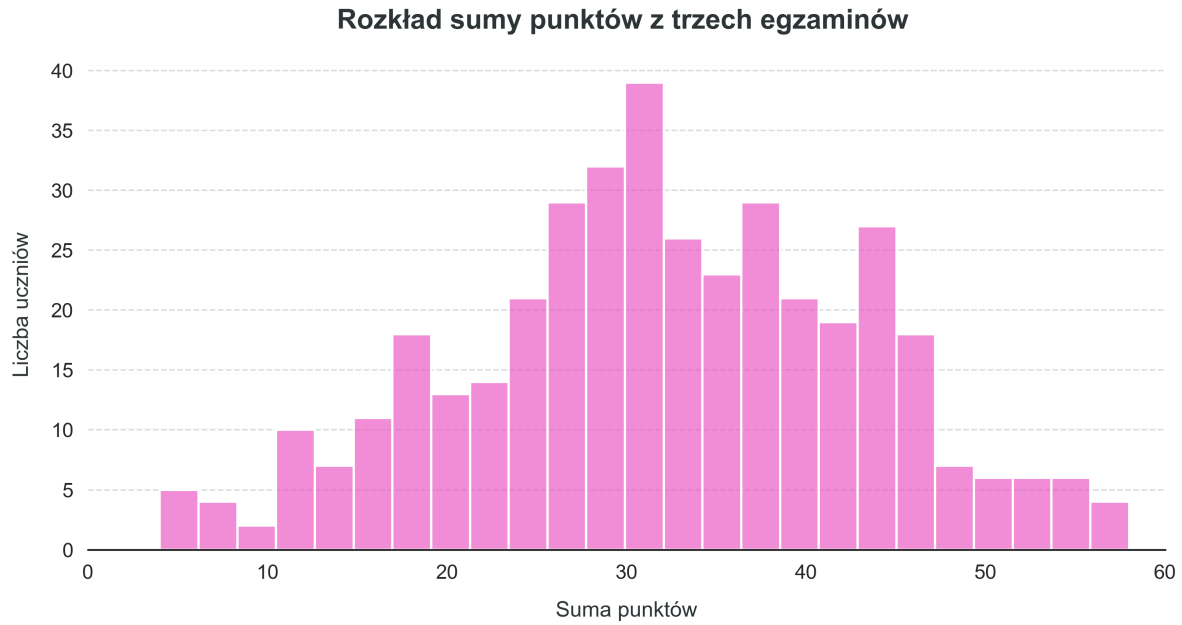
Wizualizacja danych

1. Wyniki ogólne

Miarą stopnia opanowania materiału z matematyki jest całkowita suma punktów uzyskanych z trzech egzaminów. Poniższy wykres obrazuje te rezultaty, przedstawiając rozkład sumy wyników $G_1 + G_2 + G_3$. Wyraźnie widać na nim tendencję centralną wokół wartości 30 punktów, a także ogólny rozkład wyników na tle całej grupy. W tabeli 1 przedstawiono podstawowe miary położenia i rozproszenia dla sumy punktów wszystkich 397 badanych osób. Dopiero po ustaleniu tych wartości brzegowych możliwe jest rzetelne sprawdzenie, czy podział ze względu na miejsce zamieszkania (*address*) istotnie różnicuje te wyniki. W dalszej części sprawozdania skupimy się na porównaniu grupy miejskiej (U) oraz wiejskiej (R), aby zweryfikować, czy lokalizacja szkoły i domu ma wpływ na efektywność nauki.

Tabela 1: Podstawowe statystyki opisowe sumy punktów ($G_1 + G_2 + G_3$) dla całej grupy.

Statystyka	**Wartość**
Liczność (n)	397
Średnia ($\bar{x}$)	31,95
Mediana ($\tilde{x}$)	31,00
Wariancja (s^2)	123,74
Odchylenie standardowe (s)	11,12



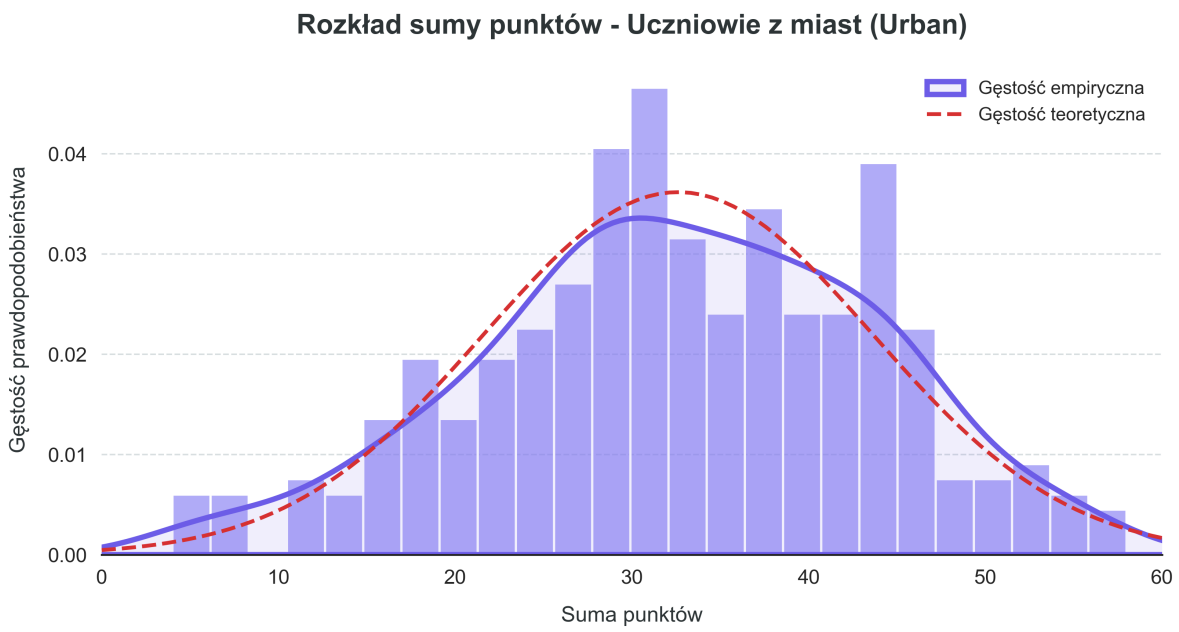
Rysunek 1: Histogram rozkładu sumy wyników ($G_1 + G_2 + G_3$) dla wszystkich badanych uczniów.

Rozkład całkowitej sumy punktów wykazuje duże podobieństwo do krzywej rozkładu normalnego. Potwierdza to niemal identyczna wartość średniej arytmetycznej ($\bar{x} \approx 31,44$) oraz mediany ($Me = 31,00$). Taka zbieżność miar położenia świadczy o symetrii rozkładu – odsetek uczniów osiągających wyniki powyżej przeciętnej jest niemal taki sam, jak odsetek uczniów z wynikami poniżej średniej.

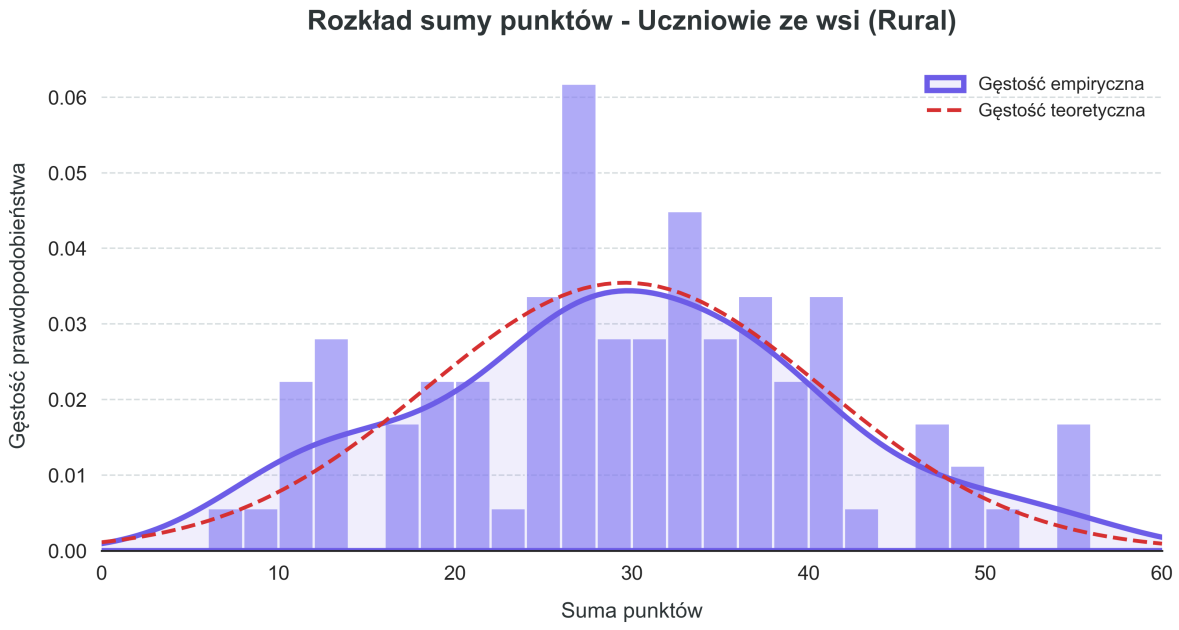
2. Podział sumy wyników względem zmiennej kategoryzującej

W tej części sprawozdania skupiono się na głównym celu badawczym projektu. Zbiór danych został podzielony na dwie rozłączne podgrupy na podstawie zmiennej kategoryzującej *address*.

Celem tego podziału jest wstępna ocena, czy miejsce zamieszkania determinuje wyniki osiągane z egzaminów matematycznych. Poniżej zestawiono podstawowe miary statystyczne dla obu grup oraz histogramy tych rozkładów, co pozwoli na zaobserwowanie ewentualnych dysproporcji w miarach położenia i rozproszenia. Zauważone różnice posłużą następnie jako podstawa do sformułowania hipotez badawczych, które zostaną zweryfikowane za pomocą formalnych testów statystycznych.



Rysunek 2: Histogram rozkładu sumy wyników ($G_1 + G_2 + G_3$) dla uczniów z miasta.



Rysunek 3: Histogram rozkładu sumy wyników ($G_1 + G_2 + G_3$) dla uczniów ze wsi.

Tabela 2: Porównanie statystyk opisowych sumy punktów dla obszarów miejskich (U) i wiejskich (R).

Statystyka	**Obszar miejski (U)**	**Obszar wiejski (R)**
Liczność (n)	308	89
Miary położenia		
Średnia arytmetyczna ($\bar{x}$)	32,62	29,61
Średnia geometryczna ($\bar{x}_{geo}$)	30,23	27,13
Średnia harmoniczna ($\bar{x}_{harm}$)	26,74	24,15
Średnia ucinana 5% ($\bar{x}_{uc}$)	32,78	29,43
Średnia winsorowska 5% ($\bar{x}_{win}$)	32,66	29,48
Kwartyl dolny (Q_1)	26,00	23,00
Mediana ($\tilde{x}$)	33,00	29,00
Kwartyl górny (Q_3)	41,00	37,00
Miary rozproszenia		
Wariancja (s^2)	121,67	126,65
Odchylenie standardowe (s)	11,03	11,25
Rozstęp międzykwartylowy (IQR)	15,00	14,00
Miary kształtu rozkładu		
Skośność (γ_1)	-0,20	0,10
Kurtoza (γ_2)	-0,29	-0,31

3. Szczegółowa analiza parametrów statystycznych

W celu wyciągnięcia precyzyjnych wniosków z przeprowadzonych obliczeń (zestawionych w tabeli powyżej), dokonano porównania wyznaczonych metryk w trzech kluczowych kategoriach: miar położenia, zmienności oraz kształtu rozkładu.

Miary położenia (średnia arytmetyczna, mediana i miary alternatywne) Miary tendencji centralnej wskazują na zauważalną przewagę uczniów uczęszczających do szkół miejskich. Średni wynik sumy punktów w grupie miejskiej wynosi $\bar{x}_U = 32,62$, podczas gdy w grupie wiejskiej jest to $\bar{x}_R = 29,61$. Różnica ta wynosi około 3 punktów na korzyść uczniów z miast. Podobną różnicę (4 punkty) widać w przypadku mediany: $\tilde{x}_U = 33,00$ wobec $\tilde{x}_R = 29,00$.

Powyższe wnioski znakomicie potwierdzają również tzw. miary odporne na wartości skrajne, czyli średnia ucinana oraz winsorowska. Po matematycznym odrzuceniu lub wyrównaniu 5% najsłabszych i najlepszych wyników, nowe średnie zmieniają się zaledwie o ułamki punktów (np. dla miast średnia ucinana wynosi 32,78, a dla wsi 29,43). Fakt, że w obu podzbiorach klasyczna średnia, mediana oraz miary odporne przyjmują bardzo zbliżone wartości, świadczy o tym, że rozkład wyników jest wysoce symetryczny. Wyniki nie są sztucznie zawyżane ani zaniżane przez ekstremalne anomalie (np. pojedyncze osoby z wynikiem 0 punktów). Środek ciężkości danych trafnie i wiarygodnie opisuje osiągnięcia typowego ucznia z danej grupy.

W celu pogłębienia analizy wyznaczono dodatkowo średnią geometryczną i harmoniczną (wykluczając wartości zerowe). Zgodnie z matematyczną nierównością Cauchy'ego, są one zawsze niższe od średniej arytmetycznej (np. w grupie miejskiej wynoszą odpowiednio 30,23 oraz 26,74). Kluczowy jest jednak fakt, że niezależnie od zastosowanego rodzaju średniej, przewaga uczniów z miasta nad uczniami ze wsi zawsze zostaje zachowana i oscyluje wokół 2,5 do 3 punktów. Dowodzi to, że zaobserwowana różnica w poziomie wiedzy jest zjawiskiem trwałym, niezależnym od wybranej metody uśredniania danych.

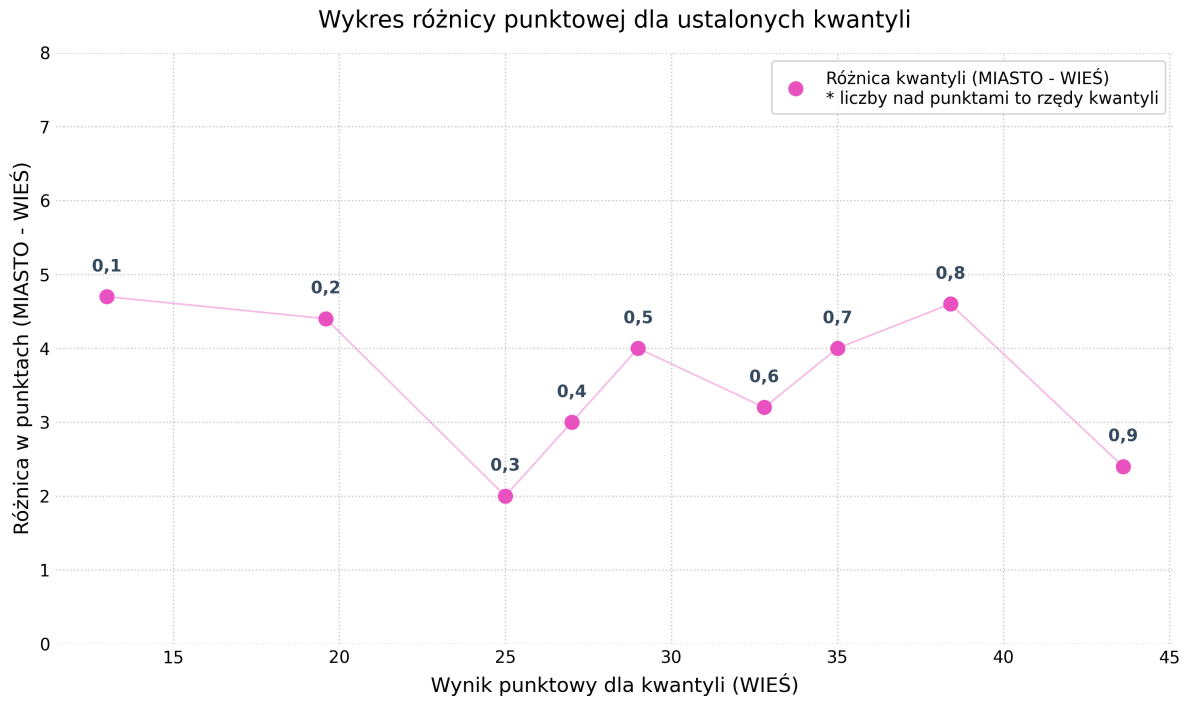
Analiza rozproszenia (odchylenie standardowe i rozstęp międzykwartylowy) Podczas gdy miary położenia wskazują na lepsze wyniki uczniów z miast, miary rozproszenia ujawniają bardzo zbliżony poziom zróżnicowania wiedzy w obu populacjach. Odchylenie standardowe dla obszarów miejskich wynosi $s_U = 11,03$, co jest wartością nieznacznie niższą niż na wsi ($s_R = 11,25$). Oznacza to, że uwzględniając wszystkich uczniów, wyniki na wsi są minimalnie mocniej "rozstrzelone"wokół średniej.

Wnioski te ulegają jednak lekkiemu odwróceniu, gdy zastosujemy pozycyjną miarę rozproszenia – rozstęp międzykwartylowy (IQR). Odrzuca on 25% najsłabszych oraz 25% najwyższych wyników, skupiając się na połowie najbardziej "typowych"uczniów w danej grupie. Z tabeli wynika, że dla środkowych 50% uczniów ze wsi rozstęp wyników wynosi 14 punktów, podczas gdy w mieście obszar ten rozciąga się na 15 punktów. Wynika z tego ciekawa zależność: chociaż wyniki wszystkich uczniów ze wsi są ogólnie bardziej zróżnicowane, to jednak osiągnięcia najbardziej typowej połowy z nich są do siebie bardziej zbliżone, niż ma to miejsce w przypadku uczniów z miasta. Potwierdzają to wartości kwartyli – środkowe 50% uczniów na wsi osiąga wyniki w zawężonym przedziale od 23 do 37 punktów, podczas gdy ich rówieśnicy z miasta od 26 do 41 punktów.

Miary kształtu rozkładu Parametry definiujące formę krzywej ostatecznie potwierdzają wnioski wysnute z analizy wizualnej histogramów. Współczynniki skośności w obu przypadkach oscylują wokół zera. Dla uczniów z miast współczynnik ten wynosi $-0,20$, co oznacza minimalną dominację wyników powyżej średniej (nieznaczną asymetrię lewostronną). U uczniów ze wsi skośność wynosi $0,10$, wskazując na nieznaczną asymetrię prawostronną. Z kolei kurtoza przyjmuje wartości ujemne: $-0,29$ dla miasta i $-0,31$ dla wsi. Rozkłady te są zatem nieco bardziej spłaszczone i posiadające cieńsze ogony niż w przypadku idealnego rozkładu normalnego. Odchylenia te są jednak na tyle drobne, że nie wpływają na globalną ocenę normalności obu rozkładów.

4. Analiza różnic punktowych na konkretnych przedziałach

Choć porównanie średnich i median wskazuje na przewagę uczniów z miast, pełniejszy obraz sytuacji daje analiza różnic na poszczególnych etapach rozkładu. Wykorzystano w tym celu tzw. Shift Function, który obrazuje lukę punktową osobno dla każdego decyla (od 10% najsłabszych do 10% najlepszych uczniów).



Rysunek 4: Wykres obrazujący różnicę punktową (Miasto - Wieś) w poszczególnych kwantylach.

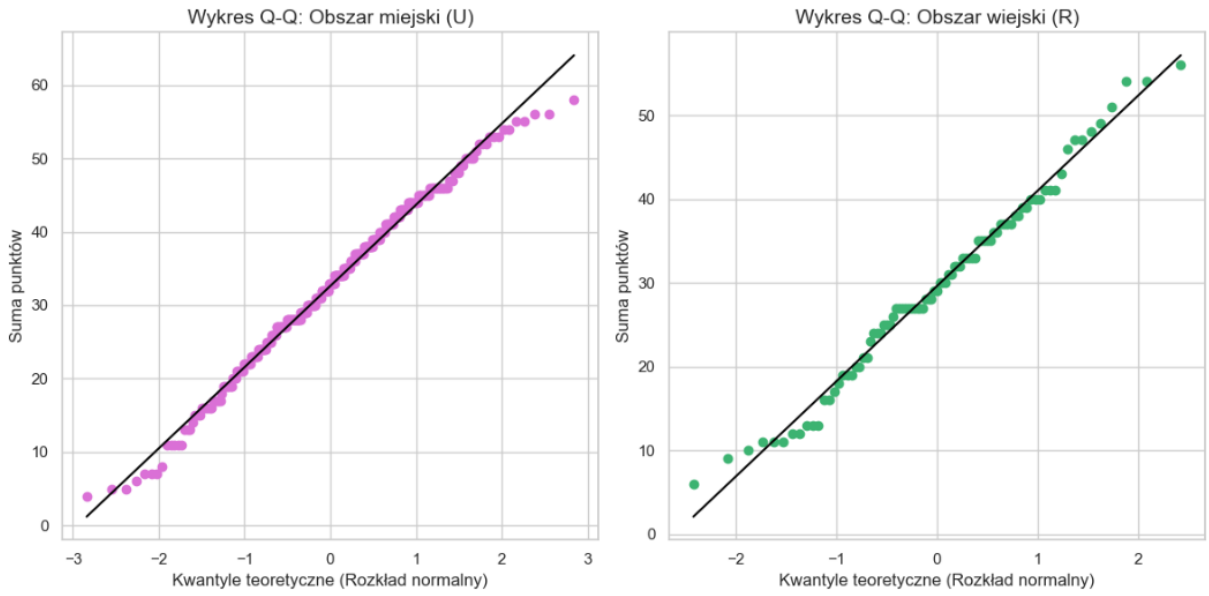
Analiza powyższego wykresu prowadzi do kluczowych wniosków, których nie widać w samej tabeli średnich:

- **Stała przewaga miasta:** We wszystkich decylach różnica jest dodatnia, co oznacza, że niezależnie od poziomu zdolności, uczniowie z miasta wypadają lepiej niż ich rówieśnicy ze wsi.
- **Największa luka wśród uczniów najsłabszych:** Największy dystans (około 4,7 pkt) obserwujemy w okolicach 10. i 20. decyla. Sugeruje to, że uczniowie mający największe trudności z matematyką radzą sobie znacznie gorzej na terenach wiejskich niż w miastach.
- **Stabilizacja w środku rozkładu:** Dla „typowych" uczniów (decyle 30–70) różnica stabilizuje się na poziomie około 3–4 punktów, co pokrywa się z wyliczoną wcześniej różnicą średnich.
- **Mniejszy dystans wśród najlepszych:** W 90. decylu (najlepsi uczniowie) różnica ponownie maleje do około 2,4 pkt. Oznacza to, że najzdolniejsi uczniowie z obu środowisk wykazują najbardziej zbliżony do siebie poziom wiedzy.

Wyniki zaprezentowane przez tę metodę nie tylko w pełni pokrywają się ze wstępnymi wnioskami płynącymi z analizy gęstości teoretycznych oraz statystyk opisowych, ale także umożliwiają głębsze zrozumienie cech obu rozkładów.

5. Diagnostyka normalności rozkładów – wykresy Q-Q

Po analizie wskaźników liczbowych (w tym miar kształtu, takich jak skośność i kurtoza), kolejnym krokiem jest wizualna ocena normalności badanych rozkładów. W tym celu wygenerowano wykresy kwantylowo-kwantylowe (tzw. Q-Q plot) osobno dla uczniów z terenów miejskich oraz wiejskich.



Rysunek 5: Wykresy kwantylowe (Q-Q plot)

Analizując powyższe wykresy, można zauważyć, że w głównej części (dla kwantyli teoretycznych z przedziału od -2 do 2) empiryczne punkty danych dla obu grup bardzo dobrze pokrywają się z prostą, reprezentującą idealny rozkład normalny. Oznacza to, że typowe, najczęściej występujące wyniki uczniów świetnie modelują się za pomocą krzywej rozkładu normalnego.

Pewne odstępstwa od linii prostej zauważalne są jedynie na krańcach obu wykresów. W grupie miejskiej widoczne jest odchylenie w dolnym ogonie, co zgadza się z zaobserwowaną wcześniej lewostronną asymetrią (wpływ pojedynczych bardzo słabych wyników, w tym zera). Z kolei obniżenie punktów w prawym górnym rogu na obu wykresach potwierdza wyliczoną ujemną kurtozę – rozkłady są delikatnie spłaszczone, a wyniki ekstremalnie wysokie pojawiają się nieco rzadziej, niż zakłada to model teoretyczny.

Mimo tych drobnych odchyleń na ogonach, ogólny liniowy przebieg empirycznych kwantyli pozwala z dużą dozą pewności założyć normalność rozkładów w obu populacjach.

Wnioski

Przeprowadzona analiza pozwala stwierdzić, że rozkłady sumy wyników dla obu grup wykazują cechy rozkładu normalnego. Co więcej, miary rozproszenia ujawniają bardzo zbliżony poziom zróżnicowania wiedzy w badanych populacjach. Odchylenie standardowe dla obszarów miejskich wynosi **11,03** i jest niemal identyczne jak na wsi **(11,25)**. Oznacza to, że niezależnie od miejsca zamieszkania, rozrzut wyników uczniów wokół wartości uśrednionych pozostaje na podobnym poziomie.

Mimo tak zbliżonego kształtu i rozproszenia obu rozkładów, zauważalne są wyraźne różnice w miarach tendencji centralnej. Średni wynik punktowy w grupie miejskiej wynosi **32,62**, natomiast w grupie wiejskiej **29,61**, co ukazuje **różnicę około 3 punktów na korzyść uczniów z miast**. Zbliżone do siebie wartości średniej klasycznej, mediany i miar odpornych potwierdzają wysoką symetrię rozkładów. Dowodzi to również, że zaobserwowana **przewaga uczniów miejskich jest zjawiskiem trwałym**, w pełni niezależnym od zastosowanej metody uśredniania danych.

Miejsce zamieszkania wykazuje zatem **zauważalny wpływ na wyniki egzaminów z matematyki**. Zbieżność odchyleń standardowych przy jednoczesnej różnicy w średnich daje solidne podstawy do wysnucia hipotezy o wpływie pochodzenia ucznia na jego osiągnięcia edukacyjne.

Wzory

Średnia arytmetyczna Wartość przeciętna liczona jako suma wszystkich obserwacji podzielona przez ich liczbę:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \tag{1}$$

Średnia geometryczna Stosowana dla danych o charakterze iloczynowym (wyliczona dla wartości dodatnich):

$$\bar{x}_{geo} = \sqrt[n]{\prod_{i=1}^{n} x_i} = (x_1 \cdot x_2 \cdot \dots \cdot x_n)^{\frac{1}{n}} \tag{2}$$

Średnia harmoniczna Odwrotność średniej arytmetycznej odwrotności danych:

$$\bar{x}_{harm} = \frac{n}{\sum_{i=1}^{n} \frac{1}{x_i}} \tag{3}$$

Średnia ucinana (p-procentowa) Średnia liczona po odrzuceniu k najmniejszych i k największych obserwacji (gdzie $k = n \cdot p$):

$$\bar{x}_{uc(p)} = \frac{1}{n-2k}\sum_{i=k+1}^{n-k} x_{(i)} \tag{4}$$

gdzie $x_{(i)}$ oznacza wartości uporządkowane rosnąco.

Mediana i kwartyle Wartości dzielące uporządkowaną próbę na równe części (kwartyl rzędu p):

$$Q_p = x_{(\lceil n \cdot p \rceil)} \tag{5}$$

Dla mediany $p = 0,5$, dla kwartyla dolnego $p = 0,25$, dla górnego $p = 0,75$.

Wariancja z próby Mierzy przeciętny kwadrat odchylenia od średniej:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 \tag{6}$$

Odchylenie standardowe Pierwiastek kwadratowy z wariancji, wyrażony w tych samych jednostkach co badana cecha:

$$s = \sqrt{s^2} \tag{7}$$

Rozstęp międzykwartylowy (IQR) Różnica między kwartylem górnym a dolnym, mierząca rozproszenie 50% środkowych obserwacji:

$$IQR = Q_3 - Q_1 \tag{8}$$

Skośność (współczynnik asymetrii) Wykorzystuje trzeci moment centralny do oceny symetrii rozkładu:

$$\gamma_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{s^3} \tag{9}$$

Kurtoza (współczynnik spłaszczenia) Mierzy koncentrację wartości wokół średniej (w odniesieniu do rozkładu normalnego):

$$\gamma_2 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4}{s^4} - 3 \tag{10}$$